SPRINT 8 - TASCA 1:

Nivel 1

Realitza la connexió en Python amb el MySQL Workbench per a carregar tota la informació que tens en les taules.

Realitzaràs una visualització per a cada exercici. Comenta el que et crida l'atenció de graficar aquesta variable, justifica l'elecció del gràfic i interpreta els resultats en funció de les teves dades.

- Conectaremos la DB de MySQL y luego crearemos un diccionario para almacenar los DataFrames

In [24]:

```
# Primero, instalamos las bibliotecas que utilizaremos en la terminal con pip install
# Instaladas las librerías necesarias, las importamos
import pandas as pd
from sqlalchemy import create_engine

# Conectamos a la base de datos
host ='localhost'
database='transactionsT4'
user='root'
password='4443'

# Creamos una cadena de conexión
cadena_conexion = f'mysql+mysqlconnector://{user}:{password}@{host}/{database}'

# Creamos el motor de conexión
motor = create_engine(cadena_conexion)

# Creamos una lista de las tablas a cargar
nombres_tablas = ['transactions', 'credit_cards', 'companies', 'products_per_transactions', 'products',
'users_all']

# Usamos el método globals() y con un bucle for leemos cada tabla en un DataFrame para
almacenarlo en el diccionario
for nombre in nombres_tablas:
    query = f'SELECT * FROM {nombre}'
    df_name = f'df_{nombre}'
    globals()[df_name] = pd.read_sql(query, con=motor)

# Para verificar la carga correcta, accedemos a las primeras 5 filas del DataFrame de la tabla
Transactions almacenado en el diccionario
df_transactions.head()
```

Out[24]:

	id	card_id	business_id	fecha_hora	amount	declined	products_ids	user_id	lat	longitude
0	02C6201E-D90A-1859-B4EE-88D2986D3B02	CcU-2938	b-2362	2021-08-28 23:42:00	466.92	0	71, 1, 19	92	819.184.589.824	-125.275.561.984
1	0466A42E-47CF-8D24-FD01-C0B689713128	CcU-4219	b-2302	2021-07-26 07:29:00	49.53	0	47, 97, 43	170	-439.694.885.888	-1.175.251.835.904
2	063FBA79-99EC-66FB-29F7-25726D1764A5	CcU-2987	b-2250	2022-01-06 21:25:00	92.61	0	47, 67, 31, 5	275	-81.222.680.576	-129.049.879.552
3	0668296C-CDB9-A883-76BC-2E4C44F8C8AE	CcU-3743	b-2618	2022-01-26 02:07:00	394.18	0	89, 83, 79	265	-343.593.055.232	-100.555.928.064
4	06CD9AA5-9B42-D684-DDDD-A5E394FEBA99	CcU-2959	b-2346	2021-10-26 23:00:00	279.93	0	43, 31	92	337.381.445.632	158.298.210.304

- Verificamos la carga de todos los DataFrames

In [25]:

```
for nombre, dfs in globals().items():  # Llamamos a la función globals()
    if nombre.startswith('df_') and isinstance(dfs, pd.DataFrame):  # Filtramos solo los DataFrames que empiezan con 'df_'
        print(f'\nVerificación del DataFrame de la tabla: {nombre}')

        # Mostramos las primeras filas con head()
        print(f'Primeras filas de {nombre}:\n', dfs.head(), '\n')

        # Comprobamos la forma (shape)
        print(f'Shape de {nombre}:', dfs.shape, '\n')

        # Mostramos el esquema info()
        print(f'Info de {nombre}:')
```

```
    dfs.info()
    print('\n')

    # Resumen estadístico con describe()
    print(f'Descripción de {nombre}:\n', dfs.describe(), '\n')
```

```
Verificación del DataFrame de la tabla: df_transactions
Primeras filas de df_transactions:
                                     id   card_id business_id  \
0  02C6201E-D90A-1859-B4EE-88D2986D3B02  CcU-2938      b-2362
1  0466A42E-47CF-8D24-FD01-C0B689713128  CcU-4219      b-2302
2  063FBA79-99EC-66FB-29F7-25726D1764A5  CcU-2987      b-2250
3  0668296C-CDB9-A883-76BC-2E4C44F8C8AE  CcU-3743      b-2618
4  06CD9AA5-9B42-D684-DDDD-A5E394FEBA99  CcU-2959      b-2346

          fecha_hora  amount  declined   products_ids  user_id  \
0 2021-08-28 23:42:00  466.92         0      71, 1, 19       92
1 2021-07-26 07:29:00   49.53         0     47, 97, 43      170
2 2022-01-06 21:25:00   92.61         0  47, 67, 31, 5      275
3 2022-01-26 02:07:00  394.18         0     89, 83, 79      265
4 2021-10-26 23:00:00  279.93         0         43, 31       92

              lat           longitude
0   819.184.589.824    -125.275.561.984
1  -439.694.885.888  -1.175.251.835.904
2   -81.222.680.576    -129.049.879.552
3  -343.593.055.232    -100.555.928.064
4   337.381.445.632     158.298.210.304

Shape de df_transactions: (587, 10)

Info de df_transactions:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 587 entries, 0 to 586
Data columns (total 10 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   id            587 non-null    object
 1   card_id       587 non-null    object
 2   business_id   587 non-null    object
 3   fecha_hora    587 non-null    datetime64[ns]
 4   amount        587 non-null    float64
 5   declined      587 non-null    int64
 6   products_ids  587 non-null    object
 7   user_id       587 non-null    int64
 8   lat           587 non-null    object
 9   longitude     587 non-null    object
dtypes: datetime64[ns](1), float64(1), int64(2), object(6)
memory usage: 46.0+ KB


Descripción de df_transactions:
```

```
                      fecha_hora      amount    declined     user_id
count                        587  587.000000  587.000000  587.000000
mean   2021-09-06 14:55:47.325383680  256.735520    0.148211  201.359455
min              2021-03-17 02:55:00   15.050000    0.000000   60.000000
25%              2021-06-02 05:14:30  131.115000    0.000000  126.000000
50%              2021-08-27 10:25:00  257.440000    0.000000  220.000000
75%              2021-12-13 08:24:30  389.900000    0.000000  268.000000
max              2022-03-16 14:01:00  499.230000    1.000000  275.000000
std                          NaN  144.133895    0.355612   71.104417


Verificación del DataFrame de la tabla: df_credit_cards
Primeras filas de df_credit_cards:
        id user_id                         iban               pan   pin  \
0  CcU-2938     275    TR3019503122135768176386 61    5424465566813633  3257
1  CcU-2945     274  DO26854763748537475216568689    5142423821948828  9080
2  CcU-2952     273        BG45IVQL52710525608255    4556 453 55 5287  4598
3  CcU-2959     272         CR7242477244335841535     372461377349375  3583
4  CcU-2966     271        BG72LKTQ15627628377363  448566 886747 7265  4900

   cvv                                  track1  \
0  984     %B8383712448554646^WovsxejDpwiev^8604114 2?7
1  887   %B4621311609958661^UftuyfsSeimxn^0610628241?7
2  438   %B2183285104307501^CddyytcUxwfdq^5907955430?9
3  667     %B7281111956795320^XocddijBckecd^0901625 3?3
4  130  %B4728932322756223^JhlgvsuFbmwgj^7202289494 3?7

                        track2 expiring_date
0   %B7653863056044187=8007163336?3      10/30/22
1   %B4149568437843501=5107140330?1      08/24/23
2  %B6778580257827162=6906859740 0?7      06/29/21
3   %B4246154489281853=2805223916?8      02/24/23
4   %B2318571115599881=8908215784?5      10/29/24

Shape de df_credit_cards: (275, 9)

Info de df_credit_cards:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 275 entries, 0 to 274
Data columns (total 9 columns):
 #   Column         Non-Null Count  Dtype
---  ------         --------------  -----
 0   id             275 non-null    object
 1   user_id        275 non-null    object
 2   iban           275 non-null    object
 3   pan            275 non-null    object
 4   pin            275 non-null    object
 5   cvv            275 non-null    object
 6   track1         275 non-null    object
 7   track2         275 non-null    object
 8   expiring_date  275 non-null    object
dtypes: object(9)
```

memory usage: 19.5+ KB

Descripción de df_credit_cards:

	id	user_id	iban	pan	pin	\
count	275	275	275	275	275	
unique	275	275	275	275	270	
top	CcU-2938	275	TR301950312213576817638661	5424465566813633	9992	
freq	1	1	1	1	2	

	cvv	track1	\
count	275	275	
unique	232	275	
top	227	%B8383712448554646^WovsxejDpwiev^8604142?7	
freq	4	1	

	track2	expiring_date
count	275	275
unique	275	258
top	%B7653863056044187=800716336?3	10/30/22
freq	1	2

Verificación del DataFrame de la tabla: df_companies
Primeras filas de df_companies:

	company_id	company_name	phone	\
0	b-2222	Ac Fermentum Incorporated	06 85 56 52 33	
1	b-2226	Magna A Neque Industries	04 14 44 64 62	
2	b-2230	Fusce Corp.	08 14 97 58 85	
3	b-2234	Convallis In Incorporated	06 66 57 29 50	
4	b-2238	Ante Iaculis Nec Foundation	08 23 04 99 53	

	email	country	\
0	donec.porttitor.tellus@yahoo.net	Germany	
1	risus.donec.nibh@icloud.org	Australia	
2	risus@protonmail.edu	United States	
3	mauris.ut@aol.couk	Germany	
4	sed.dictum.proin@outlook.ca	New Zealand	

	website
0	https://instagram.com/site
1	https://whatsapp.com/group/9
2	https://pinterest.com/sub/cars
3	https://cnn.com/user/110
4	https://netflix.com/settings

Shape de df_companies: (100, 6)

Info de df_companies:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100 entries, 0 to 99
Data columns (total 6 columns):

```
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   company_id    100 non-null    object
 1   company_name  100 non-null    object
 2   phone         100 non-null    object
 3   email         100 non-null    object
 4   country       100 non-null    object
 5   website       100 non-null    object
dtypes: object(6)
memory usage: 4.8+ KB
```

Descripción de df_companies:

	company_id	company_name	phone	email	country	website
count	100	100	100	100	100	100
unique	100	100	100	100	15	72
top	b-2222	Ac Fermentum Incorporated	06 85 56 52 33	donec.porttitor.tellus@yahoo.net	Sweden	https://netflix.com/site
freq	1	1	1	1	11	4

Verificación del DataFrame de la tabla: df_products_per_transactions
Primeras filas de df_products_per_transactions:

	id_transaction	id_product
0	FE96CE47-BD59-381C-4E18-E3CA3D44E8FF	3
1	FE809ED4-2DB6-55AC-C915-929516E4646B	23
2	FD9CBCCD-8E1E-8DA1-4606-7E3A6F3A5A65	37
3	FD89D51B-AE8D-77DC-E450-B8083FBD3187	3
4	FD2E8957-414B-BEEC-E9AD-59AA7A8A6290	83

Shape de df_products_per_transactions: (1457, 2)

Info de df_products_per_transactions:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1457 entries, 0 to 1456
Data columns (total 2 columns):
 #   Column          Non-Null Count  Dtype
---  ------          --------------  -----
 0   id_transaction  1457 non-null   object
 1   id_product      1457 non-null   int64
dtypes: int64(1), object(1)
memory usage: 22.9+ KB
```

Descripción de df_products_per_transactions:

	id_product
count	1457.000000

```
mean     41.099520
std      29.595378
min       1.000000
25%      13.000000
50%      41.000000
75%      67.000000
max      97.000000
```

Verificación del DataFrame de la tabla: df_products
Primeras filas de df_products:

	id	product_name	price	colour	weight	warehouse_id
0	1	Direwolf Stannis	$161.11	#7c7c7c	1	WH-4
1	2	Tarly Stark	$9.24	#919191	2	WH-3
2	3	duel tourney Lannister	$171.13	#d8d8d8	1.5	WH-2
3	4	warden south duel	$71.89	#111111	3	WH-1
4	5	skywalker ewok	$171.22	#dbdbdb	3.2	WH-0

Shape de df_products: (100, 6)

Info de df_products:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 100 entries, 0 to 99
Data columns (total 6 columns):
 #   Column        Non-Null Count  Dtype
---  ------        --------------  -----
 0   id            100 non-null    int64
 1   product_name  100 non-null    object
 2   price         100 non-null    object
 3   colour        100 non-null    object
 4   weight        100 non-null    object
 5   warehouse_id  100 non-null    object
dtypes: int64(1), object(5)
memory usage: 4.8+ KB
```

Descripción de df_products:

```
              id
count  100.000000
mean    50.500000
std     29.011492
min      1.000000
25%     25.750000
50%     50.500000
75%     75.250000
max    100.000000
```

Verificación del DataFrame de la tabla: df_users_all
Primeras filas de df_users_all:

	id	name	surname	phone	email	\
0	1	Zeus	Gamble	1-282-581-0551	interdum.enim@protonmail.edu	

```
1   2  Garrett  Mcconnell  (718) 257-2412  integer.vitae.nibh@protonmail.org
2   3   Ciaran   Harrison  (522) 598-1365          interdum.feugiat@aol.org
3   4   Howard   Stafford  1-411-740-3269         ornare.egestas@icloud.edu
4   5    Hayfa    Pierce  1-554-541-2077    et.malesuada.fames@hotmail.org

     birth_date        country        city postal_code                address
0  Nov 17, 1985  United States      Lowell       73544   348-7818 Sagittis St.
1  Aug 23, 1992  United States  Des Moines       59464            903 Sit Ave
2  Apr 29, 1998  United States    Columbus       56518    736-2063 Tellus St.
3  Feb 18, 1989  United States      Kailua       77417  Ap #545-2244 Erat. Rd.
4  Sep 26, 1998  United States       Sandy       31564   341-2821 Ultrices Av.

Shape de df_users_all: (275, 10)

Info de df_users_all:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 275 entries, 0 to 274
Data columns (total 10 columns):
 #   Column       Non-Null Count  Dtype
---  ------       --------------  -----
 0   id           275 non-null    int64
 1   name         275 non-null    object
 2   surname      275 non-null    object
 3   phone        275 non-null    object
 4   email        275 non-null    object
 5   birth_date   275 non-null    object
 6   country      275 non-null    object
 7   city         275 non-null    object
 8   postal_code  275 non-null    object
 9   address      275 non-null    object
dtypes: int64(1), object(9)
memory usage: 21.6+ KB


Descripción de df_users_all:
               id
count  275.000000
mean   138.000000
std     79.529869
min      1.000000
25%     69.500000
50%    138.000000
75%    206.500000
max    275.000000
```

Ejercicio 1: Una variable numérica

Graficamos la variable recuento de id_products de la tabla products_per_transactions. Seleccionamos un histograma de frecuencia para poder ver cuales son los productos más demandados.

In [26]:

```
# Importamos librerías
import matplotlib.pyplot as plt
import pandas as pd
import seaborn as sns

sns.set_style('ticks') # damos formato el estilo de los gráficos

# Obtenemos los datos de los campos 'id_product' de la tabla 'product_per_transactions'
id_product = df_products_per_transactions['id_product']

# Contamos las ocurrencias de cada id_product y las ordenamos para que estén ascendentes
product_counts = id_product.value_counts().sort_index()

# Creamos una variable para darle color sólo para los id de producto que se hayan vendido más de 60 unidades
color = ['lightgreen' if count > 60 else 'salmon'for count in product_counts]

# Creamos el gráfico de barras
product_counts.plot(kind='bar', color = color)

# Añadimos etiquetas y título
plt.xlabel('ID Producto')  # Etiqueta para el eje x
plt.ylabel('Cantidad')   # Etiqueta para el eje y
plt.title('Productos demandados')

# Mostramos el gráfico
plt.show()
```

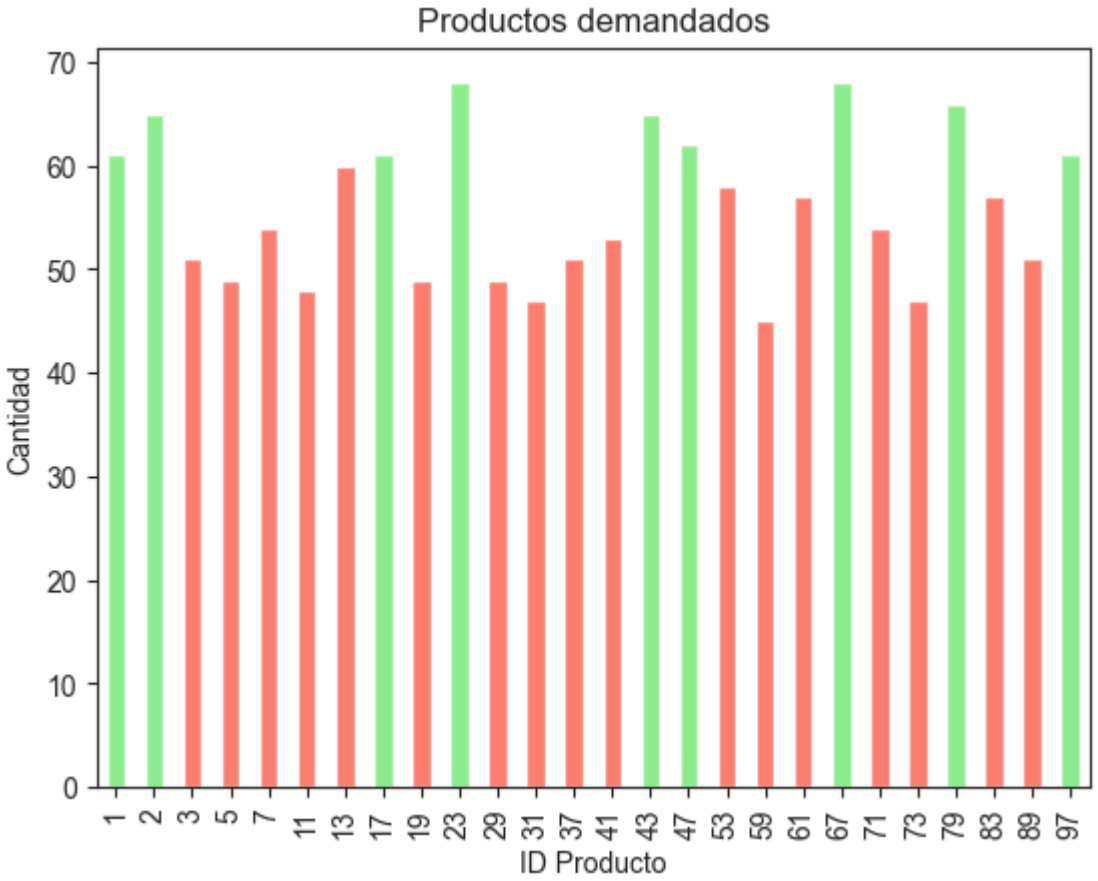

Interpretación: *En este gráfico podemos observar que los productos más demandados son los de ID: 1, 2, 17, 23, 43, 47, 67, 79 y 97. Los definimos como aquellos que superan las 60 unidades y están coloreados en verde. En base a estos datos podría recomendarse, por ejemplo, fabricar más de los productos más demandados y discontinuar o promocionar los menos demandados.*

Ejercicio 2: dos variables numéricas

Seleccionamos las variables precio y peso, para ver si existe alguna relación entre ellas. Realizaremos un gráfico de dispersión.

In [27]:

```
import matplotlib.pyplot as plt
import pandas as pd
import numpy as np


# Obtenemos los datos de los campos 'precio'y 'peso' de la tabla 'products'
precio = df_products['price']
peso = df_products['weight']

# Eliminamos el signo $ y casteamos a float
precio = df_products['price'].str.replace('$','').astype(float)


# Creamos un DataFrame temporal con los datos
data = pd.DataFrame({'precio': precio, 'peso': peso})
```

```
# Ordenamos los datos por 'peso' y luego por 'precio'
data = data.sort_values(by=['peso', 'precio'])

# Creamos el gráfico de dispersión
plt.figure(figsize=(10, 6))
scatter = plt.scatter(data['peso'], data['precio'], cmap='viridis', s=100)

# Añadimos etiquetas y título
plt.xlabel('Peso')
plt.ylabel('Precio')
plt.title('Relación entre Precio y Peso')


# Controlamos la densidad de las etiquetas del eje y para mejorar la legibilidad
from matplotlib.ticker import MaxNLocator
plt.gca().yaxis.set_major_locator(MaxNLocator(nbins=10))

# Mostramos el gráfico
plt.show()
```

```
C:\Users\mica_\AppData\Local\Temp\ipykernel_1092\165115887.py:22: UserWarning: No data for colormapping provided via 'c'. Parameters 'cmap' will be ignored
  scatter = plt.scatter(data['peso'], data['precio'], cmap='viridis', s=100)
```

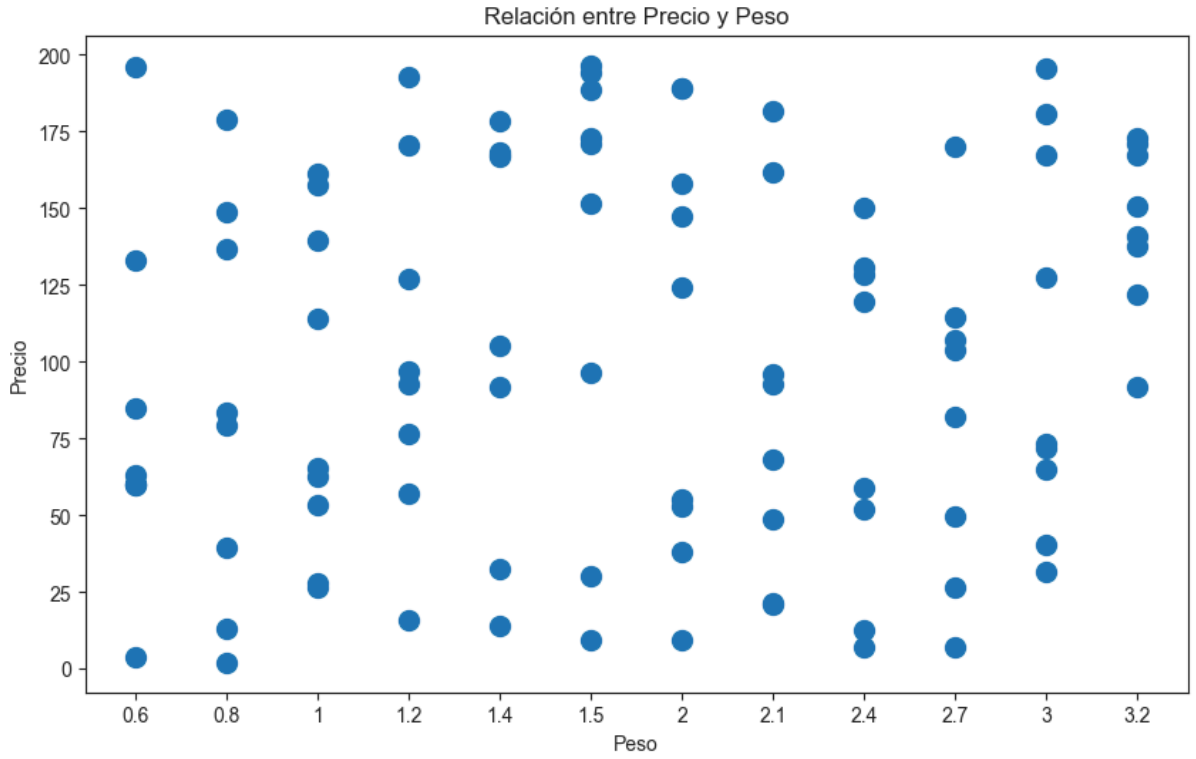

Interpretación: *Este gráfico muestra la relación entre el precio y el peso de los productos. Del gráfico podemos inferir que hay 12 categorías de peso diferentes entre los productos, que los precios oscilan entre aproximadamente*

1y

200 y que los pesos varían entre aproximadamente 0.6 y 3.2. No hay una relación clara entre peso y precio, ya que los productos se distribuyen entre todos los precios y pesos. Además los puntos no siguen una tendencia obvia. La falta de una relación clara entre el peso y el precio podría indicar que otros factores no representados en este gráfico (como la calidad del material, la marca, las características adicionales, etc.) están influyendo en el precio de los productos.

Ejercicio 3: Una variable categòrica.

Escogemos hacer un gráfico de la variable country. Como son poco valores haremos un gráfico de barras y como es una variable categórica utilizaremos la librería seaborn ya que tiene la función countplot que es específica para contar la frecuencia de cada categoría.

In [28]:

```
# Importamos las librerías
import seaborn as sns
import matplotlib.pyplot as plt

# Obtenemos los datos de los países
paises = df_users_all['country']

# Creamos el gráfico de conteo, ordenando las barras según frecuencia de mayor a menor
sns.countplot(y=paises, order=paises.value_counts().index, palette='viridis', width=0.5, hue=paises)

# Añadimos etiquetas y título
plt.xlabel('Cantidad de Usuarios')
plt.ylabel('País')
plt.title('Cantidad de Usuarios por País')

# Mostramos el gráfico
plt.show()
```

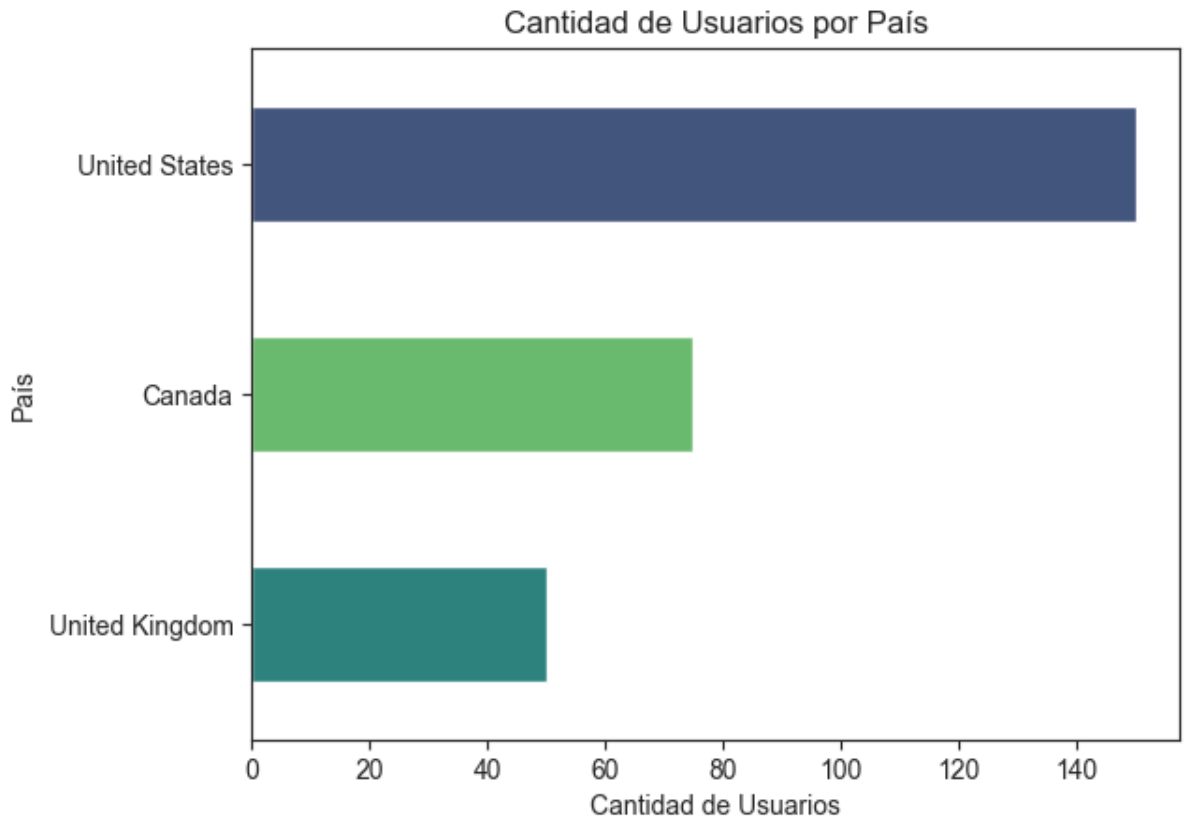

Interpretación: *En este gráfico de barras podemos ver la cantidad de usuarios según países ordenados de mayor a menor. Estados Unidos es el país que cuenta con mayor cantidad de clientes, superando los 140. Le sigue Canadá con más de 60 clientes y luego Reino Unido con poco más de 40 clientes. Basándonos en este gráfico podríamos recomendar aumentar la presencia y/o realizar promociones o campañas de marketing en Reino Unido para mejorar su participación en las transacciones.*

Ejercicio 4: Una variable categórica y una numérica.

Escojemos las variables amount(transactions) y country(companies), para ver la suma de transacciones que hay por país. Para visualizar la participación de cada país haremos un gráfico de pastel.

In [29]:

```
import matplotlib.pyplot as plt
import pandas as pd

# Unimos las tablas 'transactions' y 'companies' por los campos 'business_id' y 'company_id'
datos = pd.merge(df_transactions, df_companies, how='inner', left_on='business_id',
right_on='company_id')

# Agrupamos los datos por país y calculamos la suma de las transacciones para cada país
transacciones_por_pais = datos.groupby('country')['amount'].sum()

# Creamos el gráfico de pastel
plt.figure(figsize=(6, 6))  # Ajustamos el tamaño de la figura
plt.pie(transacciones_por_pais,
```

```
        labels=transacciones_por_pais.index, #etiquetas según el índice de la variable transacciones_por_pais (sería país)
        autopct='%1.1f%%',  #formato del número, float, con un decimal y símbolo de porcentaje
        startangle=140,     #ángulo donde comienza a dibujarse el pastel
        textprops={'fontsize': 8.5},    #tamaño del texto
        pctdistance=0.9,                #distancia de los porcentajes
        labeldistance=1.2,              #distancia de las etiquetas
        colors = plt.cm.tab20c.colors) #seleccionamos una paleta con 20 colores para que no se repitan

# Añadimos título
plt.title('Total de Transacciones por País')

# Mostramos el gráfico
plt.show()
```

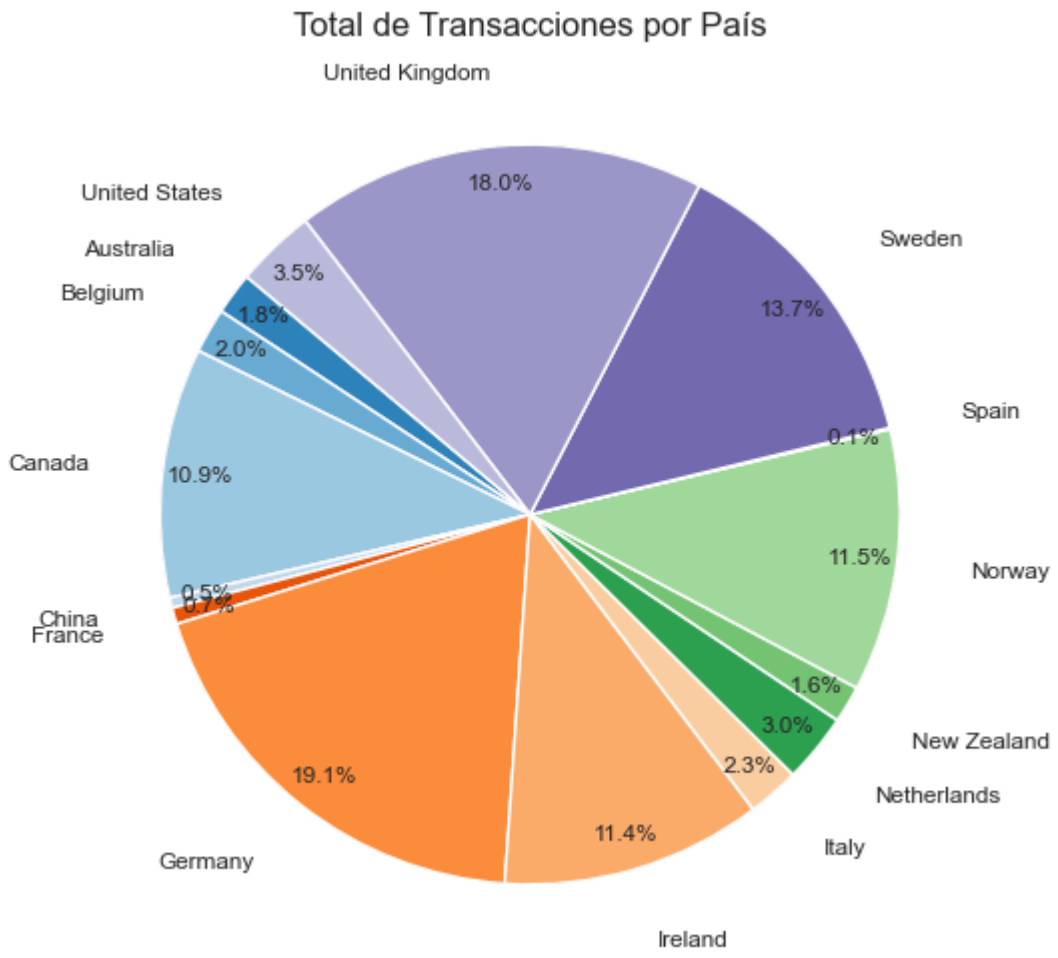

Interpretación: *Con este gráfico podemos ver que los 3 países que realizan transacciones por mayor importe son Alemania(19,1%), Reino Unido(18%) y Suecia(13.7%). Mientras que los que realizan menos transacciones por importe total son España(0.1%), China(0,5%) y Francia(0,7%). Dependiendo de la estrategia comercial de la empresa, se podría recomendar cerrar estos puntos de venta o por el contrario, aumentar las campañas de marketing en estos países si se quiere seguir apostando por ganar cuota de mercado a largo plazo.*

Ejercicio 5: Dos variables categóricas

Visualizaremos las variables países de las compañías y transacciones declinadas, en un gráfico de barras apiladas para poder ver la cantidad de transacciones rechazadas y aceptadas por país.

In [30]:

```
import pandas as pd
import matplotlib.pyplot as plt

# Unimos las tablas 'transactions' y 'companies' por los campos 'business_id' y 'company_id'
datos = pd.merge(df_transactions, df_companies, how='inner', left_on='business_id',
right_on='company_id')

# Agrupamos los datos por país y contamos las transacciones declinadas
# Con unstack() pivotamos el índice interno del dataframe resultante para generar columnas con los valores únicos de 'declined'
agrupados = datos.groupby('country')['declined'].value_counts().unstack()

# Renombramos las columnas para que en el gráfico, en lugar de 1 y 0, diga Aceptadas y Rechazadas con el atributo .columns
agrupados.columns = ['Aceptadas', 'Rechazadas']

# Graficamos
plt.figure(figsize=(10, 8))  # Ajustamos el tamaño de la figura
agrupados.plot(kind='bar', stacked=True, fontsize=12) #con stacked=True hacemos que las columnas sean apiladas

#Colocamos título y etiquetas a los ejes
plt.title('Estado de las transacciones por países')
plt.xlabel('País')
plt.ylabel('Cantidad de Transacciones')

plt.show()
```

```
<Figure size 1000x800 with 0 Axes>
```

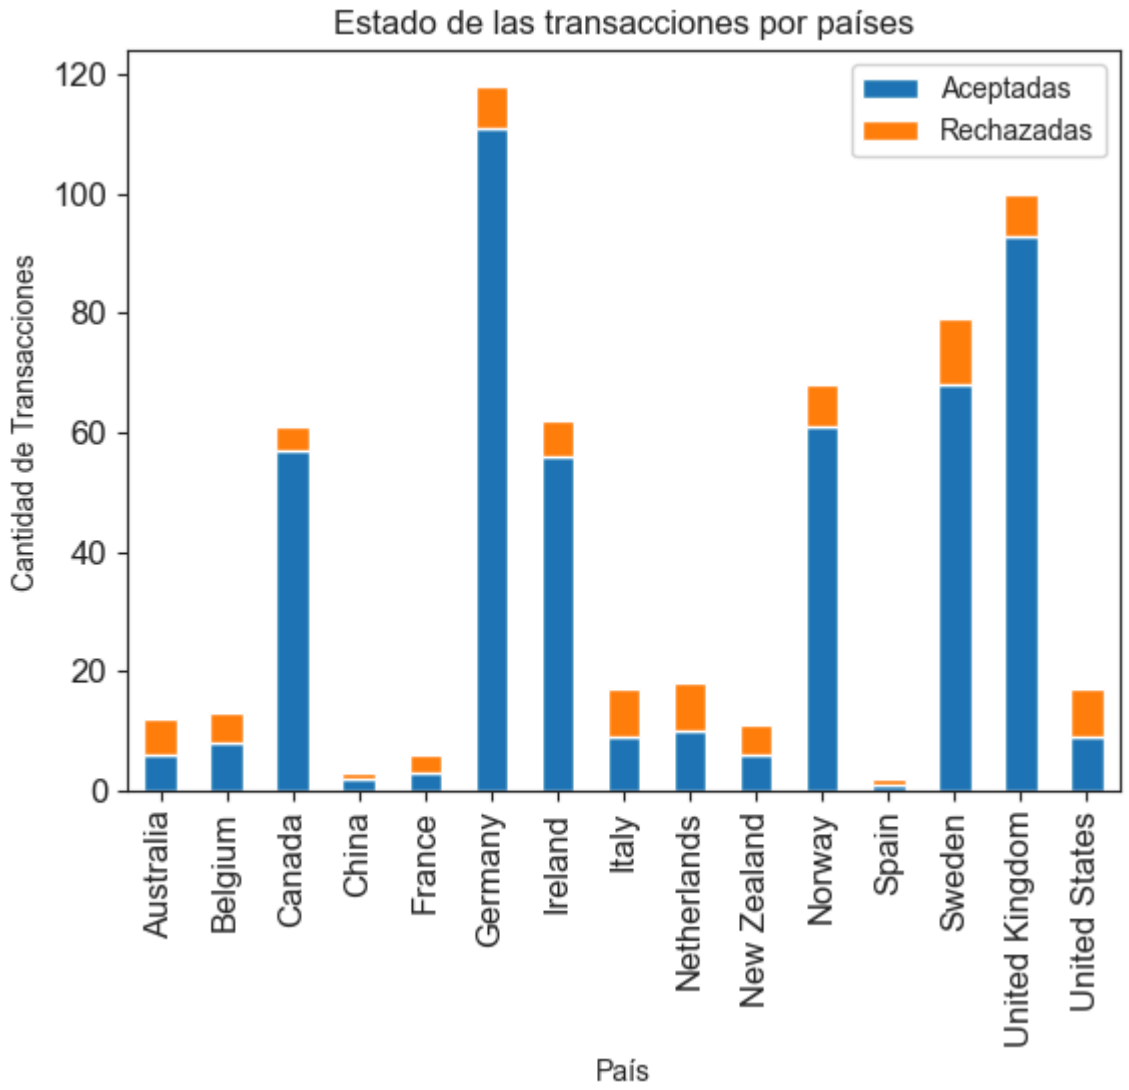

Interpretación: *Con este gráfico de columnas apiladas podemos visualizar la cantidad de transacciones realizadas por cada país y también ver cuantas de ellas han sido rechazadas (en naranja) y cuantas aceptadas (en celeste). Vemos que Alemania y Reino Unido son los países con más transacciones realizadas, pero no necesariamente los que tienen más proporción de rechazos. Australia, Francia, Italia, Países Bajos, Nueva Zelanda, España y EEUU son los que tienen mayor porcentaje de transacciones rechazadas sobre el total. Podría recomendarse indagar más sobre las causas de estos rechazos para mejorar el porcentaje de transacciones exitosas.*

Ejercicio 6: Tres Variables

Escojemos las variables amount de transacciones, fecha de nacimiento y país del usuario. Haremos un gráfico de columnas, agrupando por grupos de edades y por países la cantidad de transacciones.

In [31]:

```
import pandas as pd
import matplotlib.pyplot as plt
import numpy as np


# Unimos los DataFrames por id y user_id
datos = pd.merge(df_transactions, df_users_all, left_on='user_id', right_on='id')
```

```
# Convertimos birth_date a datetime y calculamos la edad
datos['birth_date'] = pd.to_datetime(datos['birth_date'])
datos['age'] = (pd.Timestamp.now() - datos['birth_date']).dt.days // 365  #// es una división entera que redondea al número entero hacia abajo

# Creamos grupos de edad
bins = [0, 19, 36, 51, np.inf] #np.inf es como si fuera un límite infinito
labels = ['0-18', '19-35', '36-50', '51+']
datos['age_group'] = pd.cut(datos['age'], bins=bins, labels=labels, right=False) #right=False indica intervalos semi-abiertos en el extremo derecho ej: [19, 36)

# Agrupamos los datos por país y por grupo de edad y contamos las transacciones
grouped = datos.groupby(['country', 'age_group'], observed=False).size().unstack(fill_value=0) #size() cuenta la cantidad de filas por grupo en el df

# Creamos el gráfico de barras agrupadas, damos formato a tamaño y texto
grouped.plot(kind='bar', stacked=False, figsize=(6, 6), rot=0, fontsize=12)

# Colocamos título y etiquetas a los ejes
plt.title('Transacciones por País y Grupo de Edad')
plt.xlabel('País')
plt.ylabel('Cantidad de Transacciones')
plt.legend(title='Grupo de Edad')

# Mostramos el gráfico
plt.show()
```

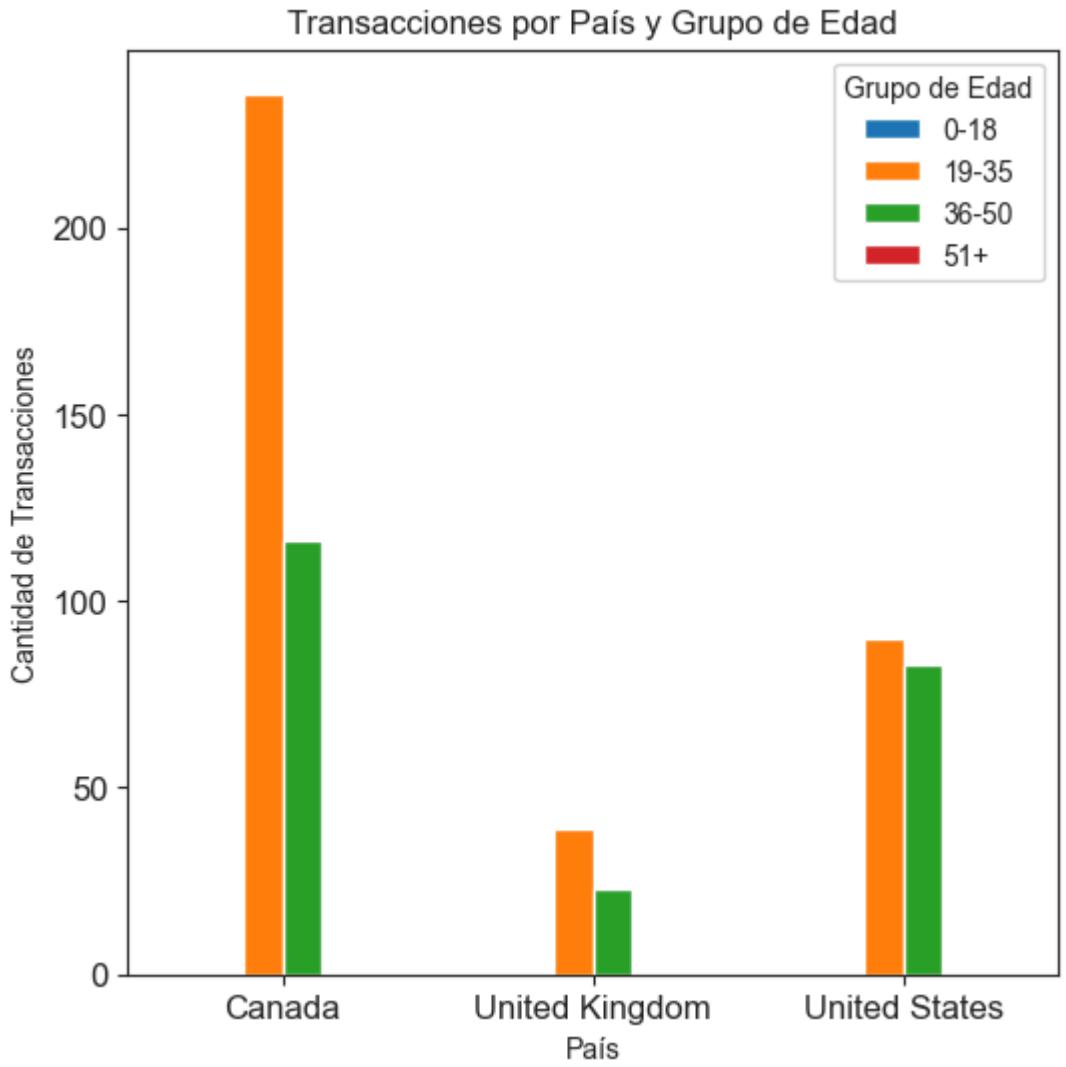

Interpretación: *Con este gráfico podemos ver que los clientes tienen entre 19 y 50 años, ya que no hay clientes de los otros dos grupos etarios (menores de 19 ni mayores de 51). En Canadá, que es donde se realizan la mayor cantidad de transacciones. El principal público cliente en los tres países es joven (19-35, color rojo). En Canadá y Reino Unido ese es marcadamente el público principal, mientras que en EEUU la cuota está más pareja con el público que tiene más edad (36-50, color amarillo). Sería interesante profundizar en analizar qué productos prefiere cada uno de los públicos para afinar la estrategia de marketing en cada país.También se podría pensar en hacer un estudio de mercado para investigar qué otro producto podríamos ofrecer que sea de interés para el público +51 y -19. Otra opción, sería hacer campañas de marketing promocionando los productos disponibles, pero direccionadas a un público más senior (+51), todo esto si una estrategia a largo plazo fuese ganar clientes en esta franja etaria. Además, teniendo en cuenta que el canal de difusión que consume cada público es diferente, para mantener a la clientela sería recomendable realizar campañas de marketing por medio de redes sociales en Canadá y el Reino Unido enfocadas al público joven que es su principal comprador, mientras que en EEUU además de redes sociales, también puede funcionar una campaña por correo electrónico, periódicos digitales o TV dirigida al público de 36-50.*

Ejercicio 7: Graficar un Pairplot.

Pairplot es una función de la biblioteca Seaborn que sirve para trazar relaciones entre pares de variables numéricas en un conjunto de datos. Genera una cuadrícula de gráficos de dispersión para

cada par de variables, lo que permite visualizar rápidamente las relaciones entre ellas. Como está diseñada para trabajar principalmente con variables numéricas, escojemos las tablas Transactions y Companies del Dataframe y Pairplot seleccionará automáticamente sólo las variables que considera numéricas, descartando las categóricas.

In [32]:

```
import seaborn as sns
import pandas as pd

# Unimos los DataFrames
datos = pd.merge(df_transactions, df_companies, left_on='business_id', right_on='company_id')

# Graficamos
sns.pairplot(data=datos, hue="country") #diferenciamos los países por color para poder tener otro nivel de análisis
```

Out[32]:

<seaborn.axisgrid.PairGrid at 0x238ff713c80>

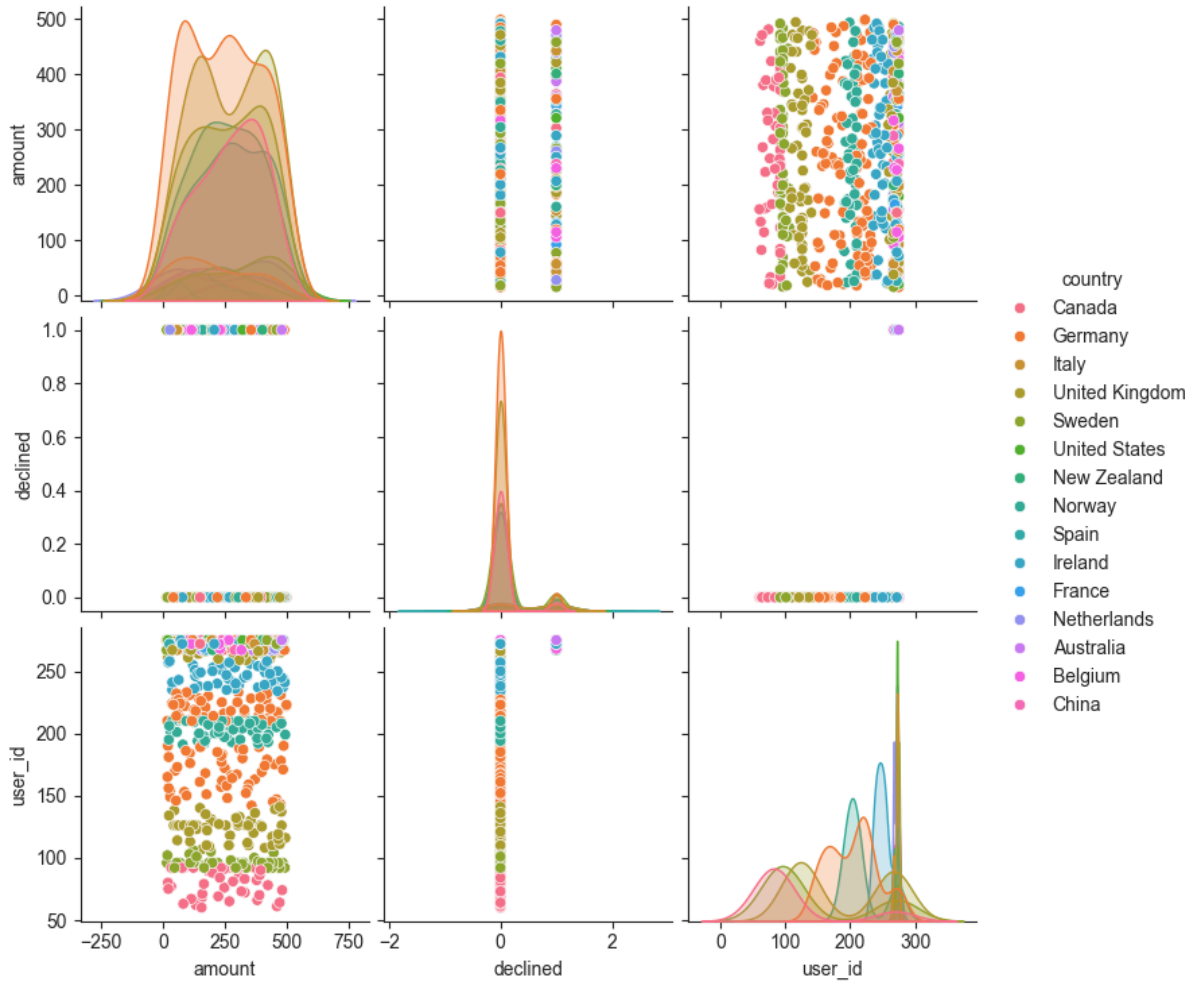

Interpretación: Las variables seleccionadas por seaborn son amount, declined y user_id. Aunque declined y user_id sean categóricas, las analizaremos igualmente. Los colores representan los países de cada compañía. Comenzaremos analizando los gráficos de arriba a abajo, de izquierda a derecha. El **primer gráfico** muestra la distribución de la variable amount, vemos que sus valores se encuentran entre 0 y 500. El **segundo gráfico y el cuarto** muestran la relación entre amount y

declined, se ve claramente que declined admite sólo dos valores 0 y 1, ya que es un booleano. Esto mismo se visualiza claramente en el **gráfico cinco**, que muestra la distribución de declined, donde se ve una distribución concentrada en sólo dos valores, uno con mayor frecuencia que el otro (el 0=FALSE, ya que la mayoría de trasacciones han sido aceptadas). El **tercer y septimo gráfico** muestran la relación entre amount y user_id, podemos ver que los datos están bastante dispersos lo que indicaría que no hay una tendencia clara, es decir que la cantidad no parece estar relacionada con el id de usuario. Por los colores podemos deducir que el id de usuario se relaciona con el país de la compañía siguiendo un orden, por ejemplo vemos que las empresas ubicadas en Canadá se encuentran sólo entre los Id de usuario más pequeños, luego siguen Suecia, Reino Unido y así sucesivamente. En el **sexto y octavo gráfico** encontramos la relación entre declined y user_id, donde vemos que sólo los usuarios con id más alto son los que han tenido transacciones declinadas. Esto podría indicar algún sesgo en los datos o algún problema por ejemplo con las ventas realizadas en estos países, ya que justo son los últimos clientes registrados los únicos que han tenido transacciones declinadas. Valdría la pena ingdagar un poco más en esta cuestión. Por último, en el **noveno gráfico** vemos la distribución de la variable user_id que adopta los valores aproximadamente desde 50 hasta 300.

Nivel 2

Ejercicio 1: Correlación de todas las variables numéricas

Analizaremos la correlación de todas las variables numéricas que consideramos relevantes (amount, user_id, id_product, declined, price y weight). Para esto utilizaremos una matriz de correlación y la visualización Heatmap (mapa de calor) de Seaborn.

In [33]:

```
import seaborn as sns
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt


# Seleccionamos los DataFrames necesarios
products = df_products
ppt = df_products_per_transactions
transactions = df_transactions

# Unimos los DataFrames
products_ppt = pd.merge(products, ppt, left_on='id', right_on='id_product')
merged = pd.merge(products_ppt, transactions, left_on='id_transaction', right_on='id')

# Como queremos visualizar 'precio' la transaformamos quitando el signo $ para que sea una variable numérica
merged['price'] = merged['price'].replace(r'[\$]', '', regex=True).astype(float)

# Seleccionamos los campos que queremos analizar
seleccion = merged[['amount', 'user_id','declined', 'id_product', 'price', 'weight']]

# Primero calculamos la matriz de correlación, redondeamos a 2 decimales
matriz_correlacion = seleccion.corr().round(2)

# Configuramos el tamaño del gráfico
```

```
plt.figure(figsize=(6, 6))

# Creamos el heatmap
sns.heatmap(matriz_correlacion,
            annot=True,     #annot=true añade los valores a los recuadros
            cmap='coolwarm', # con esto le damos el estilo de colores
            vmin=-1, vmax=1) # establecemos valores máximos y mínimos para que coincida con el coeficiente de correlación

# Mostramos el gráfico
plt.title('Matriz de Correlación')
plt.show()
```

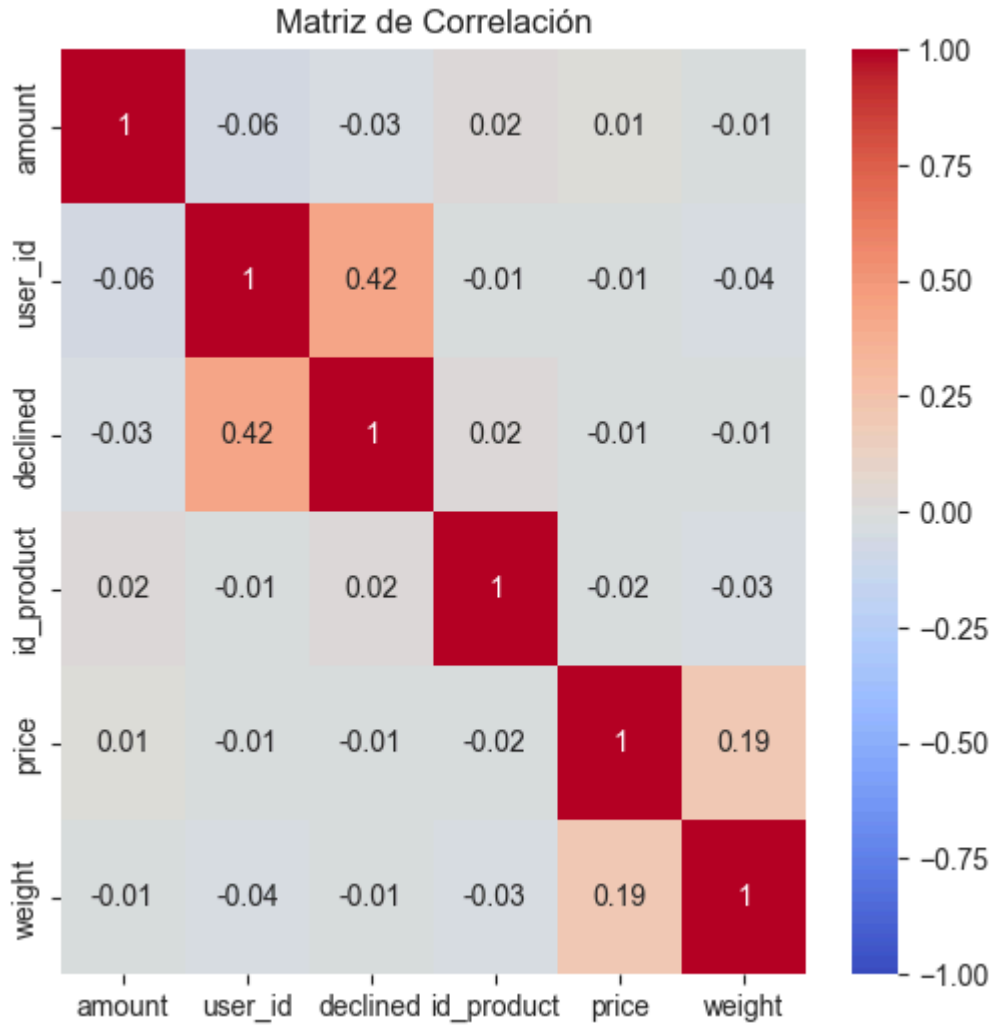

Interpretación: *La matriz de correlación sirve para ver las relaciones que se establecen entre dos variables, la diagonal siempre dará 1 ya que es la relación de cada variable con sigo misma. Utilizamos esta matriz para graficar el mapa de calor, en el mapa podemos ver que los recuadros coloreados de rojo es porque tienen una relación positiva fuerte (de valor coeficiente de Pearson = 1), mientras que si es celeste la relación es negativa fuerte (Coef. de Pearson = -1). En este caso, las variables no presentan indicios de una correlación significativa entre ellas. Las únicas dos que están coloreadas son declined y user_id con un coeficiente = 0,42 lo que indica una relación positiva moderada, esto significa que cuando una crece la otra también lo hace. Algo similar ocurre con price y weight, pero el coeficiente es de 0,19, lo que indica una relación positiva débil. Para el resto de los*

recuadros el color es gris, ya que los valores son tan bajos que no serían estadísiticmente significativos como para definir que existe una correlación entre las variables analizadas.

Ejercicio 2: implementa un jointplot

El joinplot es una visualización de Seaborn que sirve como herramienta para analizar la relación entre dos variables numéricas y sus distribuciones marginales. La aprovecharemos para indagar entre la relación de id_usuario e importe.

In [34]:

```
# Queremos analizar la relación entre id_usuario y amount, pero también colorear según el país de usuario

# Unimos los DataFrames
transact_users = pd.merge(df_transactions, df_users_all, left_on='user_id', right_on='id')

# Definimos el tamaño del lienzo, la paleta de colores y el estilo
plt.figure(figsize=(12, 10))

# Creamos el gráfico y colocamos etiquetas a los ejes
grafico = sns.jointplot(x='user_id', y='amount', data=transact_users, hue='country')
plt.xlabel('ID usuario')
plt.ylabel('Importe(€)')

# Reubicamos la leyenda
grafico.ax_joint.legend(loc='upper right', bbox_to_anchor=(1, 1))

# Movemos el título a la parte superior y fuera del gráfico
plt.suptitle('Relación ID usuario e Importe(€)', y=1.02, fontsize=16)

plt.show()
```

```
<Figure size 1200x1000 with 0 Axes>
```

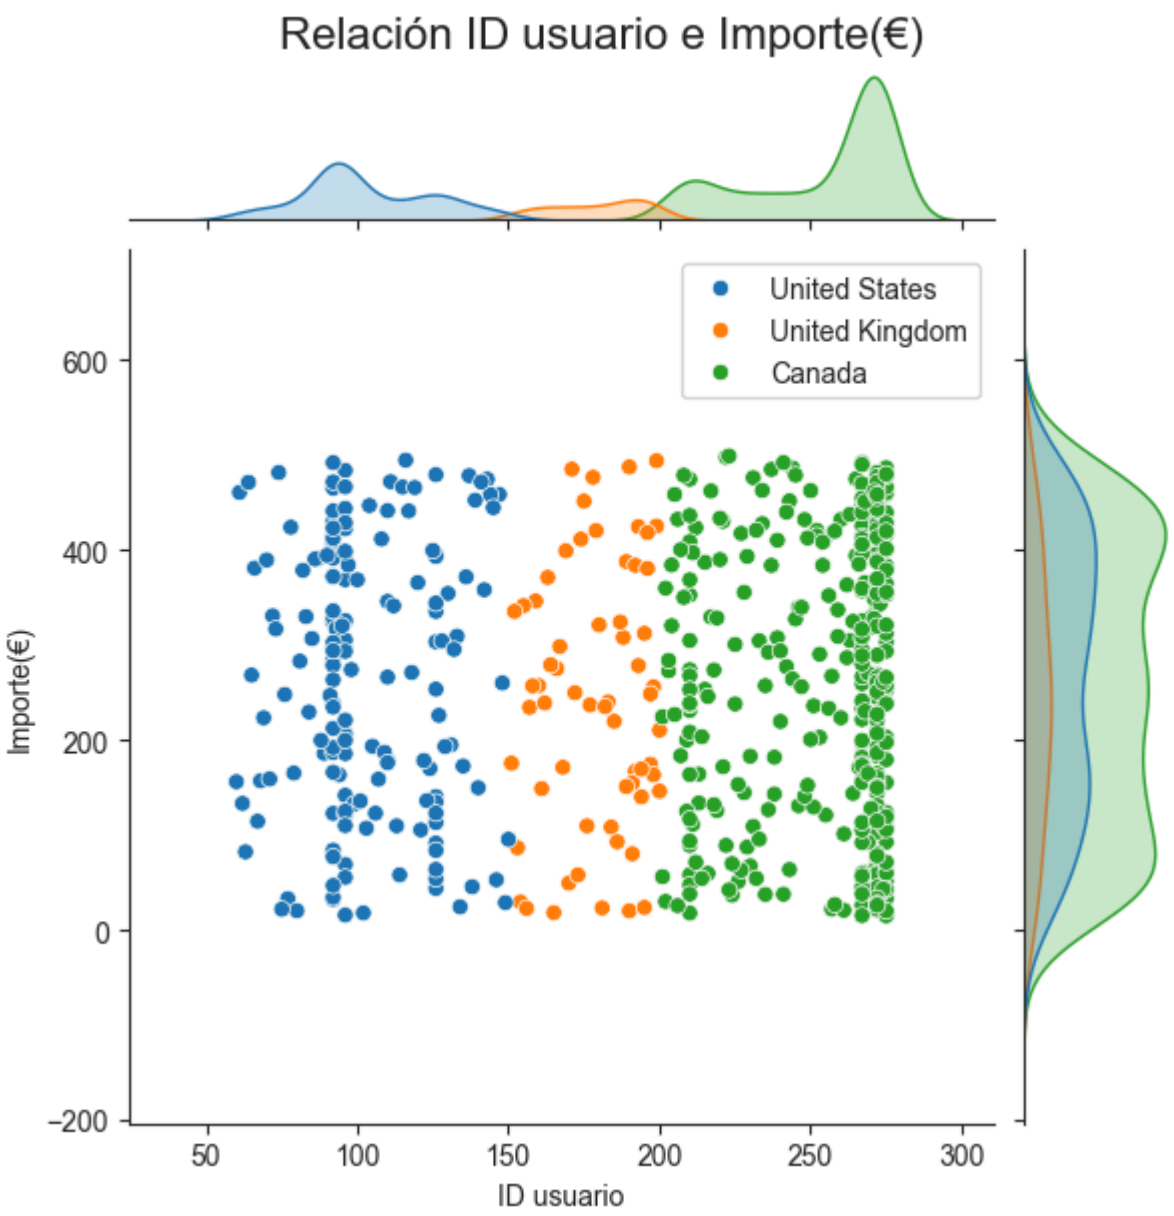

Interpretación: *No se observa una relación clara entre el ID de usuario y el Importe, ya que todos ellos parecen realizar compras de distintos montos, pero sí observamos ciertas concentraciones de puntos que comentaremos luego. Los importes van aproximadamente entre 0 y 500€. Y el id de usuario se distribuye entre 60 y 275. Podemos ver que los usuarios con el id más alto (entre 200 y 275), los de Canadá (color amarillo), son los que han realizado mayor cantidad de transacciones. A su vez, la mayor concentración de puntos dentro del gráfico de dispersión de Canadá ocurre entre los IDs que van del 250 al 275. Aquí es donde se concentra la mayor cantidad de transacciones, por eso vemos que la distribución que se muestra en el gráfico de densidad en la esquina superior derecha del joinplot se concentra más hacia la derecha. Esta mayor cantidad de transacciones puede deberse, como ya hemos visto con el pairplot, simplemente a que hubo mayor proporción de transacciones declinadas entre estos usuarios y han tenido que realizar nuevamente la transacción. Por otro lado, vemos que los usuarios con ID entre 150 y 200, del Reino Unido (color rojo), son los que han hecho menor cantidad de transacciones, pero estas tienen una distribución bastante uniforme entre todos los usuarios de ese país. Por último, los usuarios con ID entre 60 y 150 son los de EEUU (color azul), entre ellos también podemos ver una concentración de los puntos en el diagrama de dispersión y también en el gráfico de densidad azul de la esquina superior izquierda. La principal concentración de puntos se da cerca del ID de usuario 100 y otra concentración menor*

ocurre cerca del ID 120. Lo que indicaría que hay 3 o 4 principales compradores dentro de los usuarios de este país.

Nivel 3

Ejercicio 1: Implementa un Violinplot combinado con otro tipo de gráfico

Un Violinplot es similar a un diagrama de caja y bigotes, pero incorpora también al análisis la distribución de los datos después de agruparlos por una o más variables. Para continuar con el análisis del gráfico anterior, escogemos la variable amount y la agruparemos según países de los usuarios, distinguiremos los colores según declined. Y al lado, nos enfocaremos sólo en las transacciones declinadas y mostraremos la relación entre amount e id de usuarios en un gráfico de dispersión.

In [35]:

```
# Creamos el lienzo para colocar los dos gráficos con una fila y dos columnas
fig, axs = plt.subplots(1, 2, figsize=(12, 6))

# Nombramos ax1 y ax2 a cada uno de los gráficos para que sea más fácil trabajar con sus títulos y ejes
# Primer gráfico: violinplot
ax1 = sns.violinplot(x='amount',
                     y='country',
                     hue='declined',
                     data= transact_users,
                     ax=axs[0])

# Cambiamos el nombre de los ejes y añadimos título al primer gráfico
ax1.set_xlabel("Importe(€)", fontsize=14)
ax1.set_ylabel("País", fontsize=14)
ax1.set_title('Distribución del Importe', fontsize=16)

# Para el segundo gráfico filtraremos el df sólo por las transacciones declinadas para ver la relación entre user_id y amount en un gráfico de dispersión
transacciones_declinadas = transact_users[transact_users['declined'] == 1]

# Segundo gráfico: gráfico de dispersión
ax2 = axs[1].scatter(x=transacciones_declinadas['user_id'], #el eje al usar matplot se pasa antes! no como parámetro como en seaborn
                     y=transacciones_declinadas['amount'])

# Cambiamos el nombre de los ejes y añadimos el título para el segundo gráfico
axs[1].set_xlabel('ID Usuario', fontsize=14)
axs[1].set_ylabel('Importe', fontsize=14)
axs[1].set_title('Transacciones declinadas: usuario vs. Importe', fontsize=16)

fig.tight_layout() #Ajusta automáticamente los parámetros para que se ajusten dentro de la figura

plt.show()
```

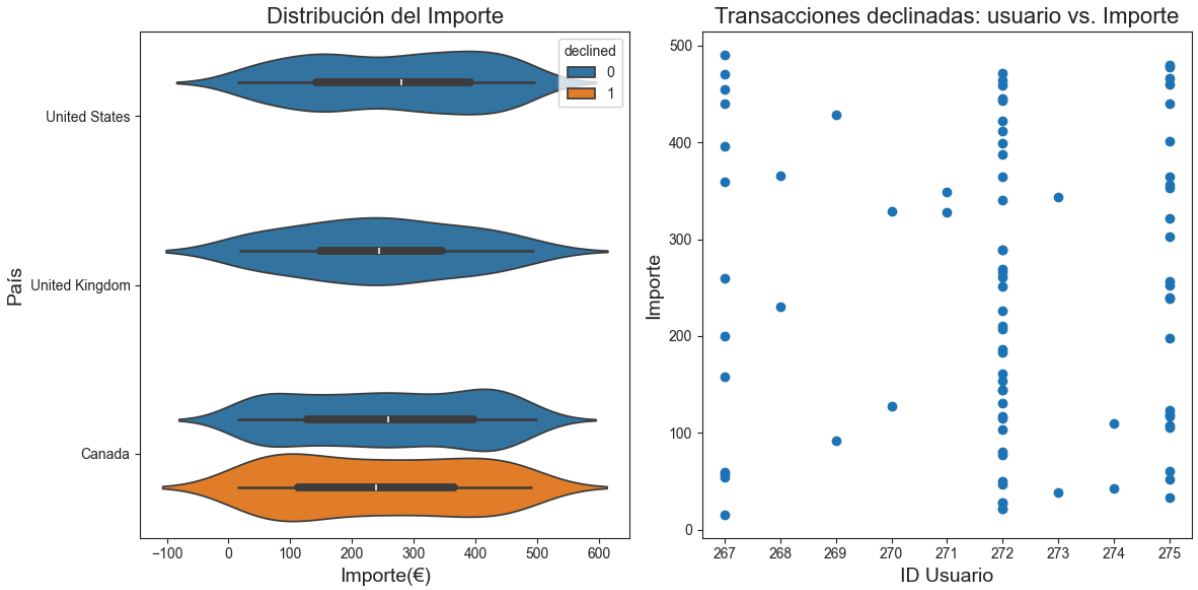

Interpretación: *El gráfico violinplot (gráfico 1, de la izquierda) enseña como se distribuye el importe de las transacciones por país de usuario y tambíen por estado(aceptada/rechazada). Vemos que este importe oscila entre 0€ y 500€ y que la mediana de casi todos los países es cercana a 200€, siendo comparativamente un poco mayor la de EEUU. El único país que tiene usuarios con transacciones declinadas es Canadá, ya que es el único con un violinplot azul. Sus transacciones declinadas se concentran en dos montos, en mayor medida hay más transacciones rechazadas cercanas a un importe de 100€ y en segundo lugar se encuentran concentradas las transacciones rechazadas de un importe cercano a 400€, por esta razón la curvatura del violín es más marcada en estos dos sectores. El Reino Unido concentra el importe de la mayoría de sus transacciones muy cercano a la mediana, es decir no muestra tanta dispersión como Canadá o EEUU. Por su parte, EEUU concentra los importes más que nada en el último cuartil, siendo importes más altos, lo que podría explicar su mayor mediana con respecto al resto. En el gráfico de dispersión (gráfico 2, de la derecha) podemos enfocarnos en los usuarios y los importes de las transacciones que han sido declinadas, (que por el gráfico anterior ya sabemos que son sólo los usuarios de Canadá). La mayoría de las transacciones declinadas/rechazadas se dan en 3 usuarios de ID 267, 272 Y 275. Para mejorar la experiencia del usuario y disminuir el número de transacciones rechazadas en un futuro, se podría recomendar enviar una encuesta o un email para indagar el motivo de los errores y así aplicar acciones de mejora, también se podría ofrecer un descuento al usuario para futuras compras.*

Ejercicio 2: Genera un FacetGrid para visualizar múltiples aspectos de los datos simultáneamente.

Un FacetGrid es una visualización de Seaborn que permite trazar una serie de gráficos pequeños (facetas) para diferentes niveles de una variable categórica. Analizaremos las variables amount, declined y país de las compañias (como categoría) para continuar indagando sobre las transacciones declinadas.

In [36]:

```
# Ya tenemos las librerías importadas

# Unimos los DataFrames
transac_companies = pd.merge(df_transactions, df_companies, left_on ='business_id',
right_on='company_id')

# Cambiamos los nombres de las columnas para que en el gráfico aparezcan en castellano
```

```
transac_companies = transac_companies.rename(columns={'amount': 'Importe', 'country': 'País',
'declined':'Estado'})

# Y reemplazamos los valores de la columna 'Declinada' para que la leyenda sea más fácil de
comprender
transac_companies['Estado'] = transac_companies['Estado'].replace({0: 'Aceptada', 1: 'Rechazada'})

# Seleccionamos los campos que queremos analizar
datos_seleccionados = transac_companies[['Importe', 'Estado', 'País']]

# Graficamos
plt.figure(figsize=(12, 10))
g = sns.FacetGrid(datos_seleccionados, col='País', col_wrap = 5, hue= 'Estado')
g.map(plt.hist, 'Importe')

# Añadimos la leyenda
g.add_legend()
g.set_ylabels('Cantidad')

#Colocamos título
plt.subplots_adjust(top=0.9)  # Ajusta el espacio superior para dar espacio al título
g.fig.suptitle('Importe, Cantidad y Estado de las Transacciones por País') #suptitle coloca el título en
la parte de arriba

plt.show()
```

```
<Figure size 1200x1000 with 0 Axes>
```

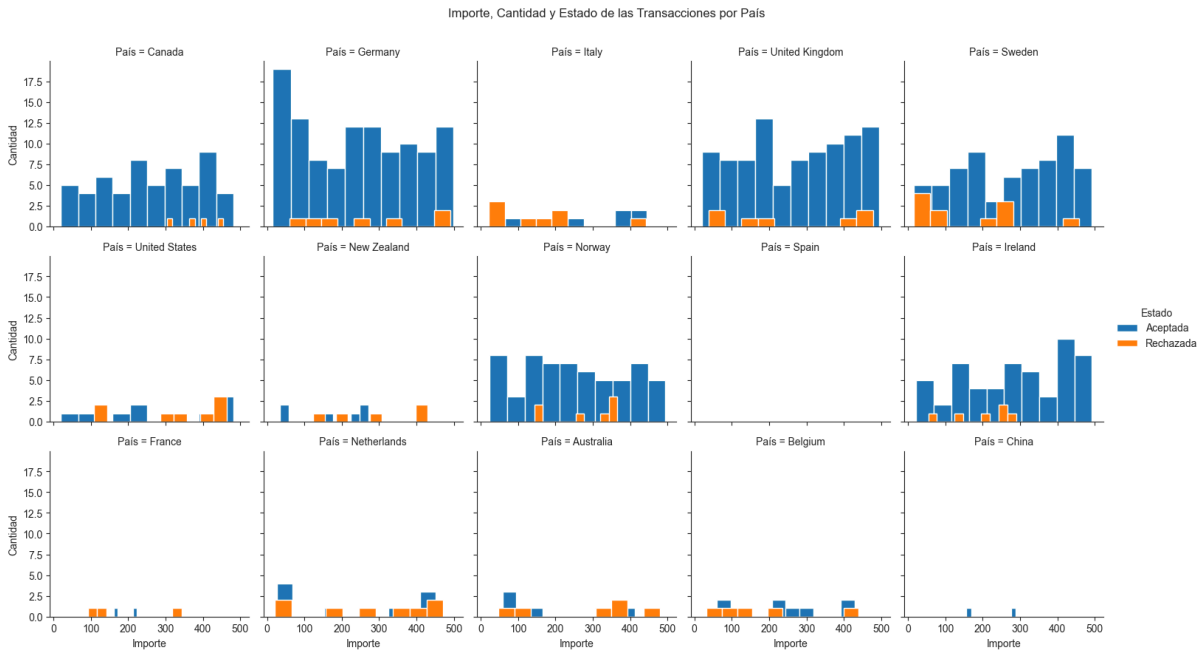

Interpretación: *En este gráfico podemos observar la distribución de la variable Importes de las transacciones según su Estado (Aceptada en celeste, Rechazada en Rojo). Cada uno de los gráficos representa uno de los países donde se ubican las empresas que realizan las transacciones. Claramente podemos corroborar lo que ya hemos visto en el gráfico de pastel del ejercicio 4: Alemania, Reino Unido y Suecia son los tres países que más volumen de transacciones han*

realizado; mientras que China, España y Francia son los que menos. Por otro lado, corroboramos lo visto en el ejercicio 5: Italia, EEUU, Nueva Zelanda, Francia, Países Bajos y Australia tienen gran proporción de sus transacciones rechazadas. Podría recomendarse contactar con las empresas de estos países para consultar y obtener un feedback sobre las transacciones rechazadas y aprovechar para informarles sobre los usuarios encontrados en el análisis del gráfico anterior que concentran gran número de estos rechazos.